

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ
УНИВЕРСИТЕТ

имени М.В.Ломоносова
механико-математический факультет

**Анализ длиннейших
последовательностей в
испытаниях Бернулли**

Курсовая работа
студента 3-го курса 309-ой группы
кафедры теории вероятностей
Мударисов Тимура Маратовича

Научный руководитель
доктор физико-математических наук, профессор
Булinsky Александр Вадимович

Москва, 2019 г.

Содержание

1	Введение	2
2	Описание модели	3
3	Случай честной монеты	4
4	Случай нечестной монеты	6
5	Симуляции	8
	Литература	10

1 Введение

Задача поиска длиннейших последовательностей в испытаниях Бернулли впервые была рассмотрена венгерским математиком П.Эрдешом(Erdős) в XX веке. Изучалась длина наибольшей последовательности орлов L_n при бросании честной монеты, где n - число бросков. Был поставлен вопрос о поведении величины L_n . Первые результаты по этой теме были получены в [2], где *G.Bateman* привел точные формулы для распределения $\mathbb{P}(L_n \leq x)$. В статье [1] *Erdős* и *Revesz* впервые исследовали асимптотику этой случайной величины. Авторы показали, что $\exists C_1, C_2 : C_1 \log n \leq L_n \leq C_2 \log n$.

Также *Revesz* в [1] предложил эксперимент:

Преподаватель предлагает студентам разделить на две группы:

- 1) В первой группе подбрасывают монетку 200 раз и записывают результаты бросков в таблицу.
- 2) Во второй группе записывают в таблицу последовательность из 200 орлов и решек на своё усмотрение.

Результаты отдают преподавателю, и он должен понять, какая из таблиц принадлежит каждой группе.

В настоящее время в изучении этой задачи получены различные результаты. Математики подошли к изучению данной темы с разных сторон: *M.S.Waterman* и *M.F.Shilling* [4] изучали асимптотические свойства, *J.Kinney* (1978) рассматривал броски до первой последовательности орлов длины k , *B.Arazi* (1977) использовал похожие идеи в задаче распознавания рукописного текста. Таким образом, видно, что аналогичные задачи возникали в различных разделах математики и прикладных науках.

В данной работе пойдет речь о теоремах, которые напрямую связаны с первоначальной постановкой вопроса, а именно: изучением длиннейшей последовательности нулей и единиц. Доказываются теоремы о поведении величины L_n для случая честной монеты, приводятся формулы для $\mathbb{P}(L_n \leq x)$ (доказанные в [2]) и рекуррентные соотношения, которые используются в симуляциях. В последнем параграфе устанавливается связь между $\mathbb{P}(L_n \leq x)$ и случайной величиной с двойным экспоненциальным распределением.

Также приводятся симуляции с использованием *Python*, для демонстрации применимости и точности некоторых полученных результатов.

2 Описание модели

Рассмотрим $X_1, X_2, \dots$ - независимые одинаково распределенные случайные величины, такие что $\mathbb{P}(X_i = 1) = p$, $\mathbb{P}(X_i = 0) = q = 1 - p$, где $p \in (0, 1)$. Пусть $L_n = \max\{k : X_i = 1, \dots, X_{i+k} = 1, i \in \mathbb{N}\}$. Обозначим $R(m, n, p) = \mathbb{P}(L_n > m)$. Сначала обсудим результаты, полученные в [2]. Как говорилось ранее, *G. Bateman* установил точные формулы для функции распределения количества орлов в данной задаче.

Теорема 1. *Дана последовательность из испытаний Бернулли, и пусть $n > k$, тогда*

$$R(m, n, p) = \sum_{j=1}^{\lfloor \frac{n}{m} \rfloor} (-1)^{j+1} \left(p + \frac{n - jm + 1}{j} q \right) \binom{n - jm}{j - 1} p^{jm} q^{j-1}$$

Доказательство этой теоремы состоит из комбинации алгебраических и вероятностных методов: поиск коэффициентов разложения $f(x) = x^t \left(\frac{1-x^m}{1-x} \right)^t$ и формула полной вероятности $\mathbb{P}(L_n \geq m) = \sum_{k=m}^n \mathbb{P}(L_n \geq m | k) \times \mathbb{P}(k)$. Видно, что данная формула не применима для вычислений и дальнейшего анализа, поэтому удобнее рассматривать асимптотические свойства L_n , а также рекуррентные формулы, позволяющие проводить компьютерные вычисления.

Для симуляций используются рекуррентные формулы из [9].

Теорема 2. 1° Пусть $p = 1/2$, тогда

$$\mathbb{P}(L_n \leq x) = \sum_{k=1}^n C_n^{(k)}(x) p^k q^{n-k}, \text{ где } C_n^{(k)}(x) = \sum_{j=1}^x C_{n-1-j}^{(k-j)} \text{ при } x < k < n, \text{ и}$$

$$C_n^{(k)}(x) = \binom{n}{k} \text{ при } 0 \leq x \leq n.$$

2° Пусть $p \neq 1/2$, тогда

$$\mathbb{P}(L_n \leq x) = \sum_{k=1}^n \bar{C}_n^{(k)}(x) p^k q^{n-k}, \text{ где } \bar{C}_{m+k}^{(k)}(x) = C_{x+1}(m, k). \text{ Причем } C_t(m, k) =$$

$$\sum_{i=0}^{t-1} C_t(m-1, k-i) - \sum_{i=1}^{t-1} C_t(m-t, k-i) + e_t(m, k), \text{ где } e_t(m, k) = 1 \text{ при } m = 0, -1 \text{ при } m = 1 \text{ и } 0 \text{ иначе.}$$

3 Случай честной монеты

Перейдем к основной части, связанной с асимптотическими свойствами L_n .

Так же рассматриваются независимые одинаково распределенные случайные величины $X_1, X_2, \dots$, такие что $\mathbb{P}(X_i = 1) = \mathbb{P}(X_i = -1) = 1/2$. Введем новые обозначения согласно [1]. $I(N, K) = \max_{0 \leq n \leq N-K} (S_{n+K} - S_n)$, где $S_n = \sum_{i=0}^n X_i$. Тогда L_n (длиннейшая последовательность из единиц) удовлетворяет $L_n = I(N, L_n) = \max_{0 \leq n \leq N-L_n} (S_{n+L_n} - S_n)$.

Сначала нам потребуется несколько полезных результатов, доказанных в [1]:

Лемма 1. *Ввиду новых обозначений имеем:*

$$\mathbb{P}(I(2N, N) \geq N - T) = \begin{cases} 2^{-N-1}(N+2) & , T = 0 \\ 2^{-N-1}(N^2 + 4 - 2^{-N+1}) & , T = 1 \\ 2^{-N-1} \frac{N^{T+1}}{T!} (1 + o(1)) & , T > 1. \end{cases}$$

Доказательство. Рассмотрим следующие события:

$A = A(T) = \{I(2N, N) \geq N - T\}$, $A_k(T) = \{S_{k+N} - S_k \geq N - T\}$. Тогда очевидно получаем следующее:

$A = A_0 \cup \bar{A}_0 \cap A_1 \cup \dots \cup \bar{A}_0 \cap \dots \cap \bar{A}_{N-1} \cap A_N$, где

$$\begin{aligned} P(\bar{A}_0 \cap \dots \cap \bar{A}_{k-1} \cap A_k) &= \sum_{k+1 \leq l_1 \leq \dots \leq l_T \leq k+N} \mathbb{P}(\bar{A}_0 \cap \dots \cap \bar{A}_{k-1} \cap A_k, X_k = X_{l_1} = \dots = X_{l_T} = 0) = \\ &= \sum_{k+1 \leq l_1 \leq \dots \leq l_T \leq k+N} \mathbb{P}(A_k, X_k = X_{l_1} = \dots = X_{l_T} = 0, S_{k-1} - S_{l_T-N-1} < k - l_T + \\ &N, S_{k-1} - S_{l_{T-1}-N-1} < k - l_{T-1} + N - 1, \dots, S_{k-1} - S_{l_1-N-1} < k - l_1 + N - (T-1)) = \\ &= 2^{-N-1} \sum_{k+1 \leq l_1 \leq \dots \leq l_T \leq k+N} \mathbb{P}(X_k = X_{l_1} = \dots = X_{l_T} = 0, S_{k-1} - S_{l_T-N-1} < k - l_T + \\ &N, S_{k-1} - S_{l_{T-1}-N-1} < k - l_{T-1} + N - 1, \dots, S_{k-1} - S_{l_1-N-1} < k - l_1 + N - (T-1)). \end{aligned}$$

Следовательно, получим три случая: $T = 0, T = 1, T > 1$. Рассматривая отдельно каждый из них, получим требуемое. $\square$

Важным следствием является следующее утверждение:

Теорема 3. *При $N \geq 2K$ верно:*

$$1^\circ. (1 - 2^{-K-1} \frac{K^{T+1}}{T!} (1 + o(1)))^{\lfloor \frac{N-2K}{K} \rfloor + 1} \leq \mathbb{P}(I(N, K) < K - T)$$

$$2^\circ. \mathbb{P}(I(N, K) < K - T) \leq (1 - 2^{-K-1} \frac{K^{T+1}}{T!} (1 + o(1)))^{\lfloor \frac{1}{2} \lfloor \frac{N-2K}{K} \rfloor \rfloor + 1}$$

Доказательство представлено в [1].

Докажем основные результаты, для случая честной монеты.

Теорема 4. Пусть $\epsilon > 0$. Тогда почти для всех $\omega \in \Omega$

1° $\exists N(\omega, T, \epsilon) : Z_N(T) \geq [\log N + T \log \log N - \log \log \log N - \log T! + \log \log e - 2 - \epsilon] = \alpha_1$, при $N \geq N_0$

2° $\exists \{N_i(\omega, T, \epsilon)\}_{i=1}^{\infty} : Z_{N_i}(T) < [\log N_i + T \log \log N_i - \log \log \log N_i - \log T! + \log \log e - 1 + \epsilon] = \alpha_2$

Доказательство. 1° Рассмотрим $N_j = N_j(T)$ - минимальное число, для которого $\alpha_1(N_j, T) = j$, тогда $\sum_{j=1}^{\infty} \mathbb{P}(Z_{N_j}(T) < \alpha_1(N_j, T)) < \infty$, т.к. $\mathbb{P}(Z_{N_j}(T) <$

$$\alpha_1(N_j, T)) \leq (1 - 2^{-j-1} \frac{j^{T+1}}{T!} (1 + o(1)))^{\lfloor \frac{1}{2} \lfloor \frac{N_j - 2j}{j} \rfloor + 1}$$

Тогда из сходимости этого ряда следует, что $\exists N : n \geq N : Z_N(T) \geq [\log N + T \log \log N - \log \log \log N - \log T! + \log \log e - 2 - \epsilon]$ для $n \geq N$

2° В доказательстве теоремы используется лемма Бореля-Кантелли:

Лемма 2. Пусть события $A_1, A_2 \dots$ таковы, что:

$$(1) \liminf_{n \rightarrow \infty} \frac{\sum_{k=1}^n \sum_{l=1}^n \mathbb{P}(A_k A_l)}{(\sum_{k=1}^n \mathbb{P}(A_k))^2} = 1.$$

$$(2) \sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty, \text{ тогда}$$

С вероятностью 1 выполняется бесконечно много событий A_n .

Воспользуемся этим фактом и рассмотрим теперь события:

$$A_j = \{I(N_j, \alpha_2(N_j, T)) < \alpha_2(N_j, T) - T\}$$

$$B_{i,j} = \left\{ \max_{0 \leq k \leq N_i - \alpha_2(N_j, T)} (S_{k + \alpha_2(N_j, T)} - S_k) < \alpha_2(N_j, T) - T \right\}, \text{ если } i < j.$$

$$C_{i,j} = \left\{ \max_{N_i \leq k \leq N_j - \alpha_2(N_j, T)} (S_{k + \alpha_2(N_j, T)} - S_k) < \alpha_2(N_j, T) - T \right\}, \text{ если } i < j.$$

Заметим, что теорема 2 гарантирует $\mathbb{P}(B_{i,j}) = 1$ при достаточно большом N_i , тогда

$$\mathbb{P}(A_i A_j) = \mathbb{P}(A_i) \mathbb{P}(C_{i,j}), \text{ а также } \mathbb{P}(A_j) = \mathbb{P}(B_{i,j}) \mathbb{P}(C_{i,j})$$

Выражая из второго равенства $\mathbb{P}(C_{i,j})$, получаем:

$$\mathbb{P}(A_i A_j) = \frac{\mathbb{P}(A_i) \mathbb{P}(A_j)}{\mathbb{P}(B_{i,j})}. \text{ То есть выполняются условия леммы 1, а следовательно}$$

$\exists \{N_i\}_{i=1}^{\infty}$, для которых выполнена нужная нам оценка.

□

Результаты, полученные *Erdős* и *Renyi*, были развиты в статьях *Deheuvels* (1985), *Foldes* [7], а так же статьях *Binwanger* и *Embrechts* (1994), где авторы применили эту идею к задаче разорения.

4 Случай нечестной монеты

В данном разделе рассматривается общий случай $p \in (0, 1)$. Приведены теоремы, показывающие характер роста функции распределения L_n , поведение математического ожидания и дисперсии при $n \rightarrow \infty$.

Введем следующие обозначения: $P(n, k)$ - вероятность того, что при n бросках длина максимальной последовательности из орлов не превосходит k . То есть $P(n, k) = F_{L_n}(k)$ - функция распределения нашей случайной величины. В силу данных определений получаем следующее:

Теорема 5. *При достаточно большом n имеем:*

$$|P(n, k) - e^{-qp^{k-\log n / \log p}}| \leq \frac{3 \log^3 n}{|\log(p)|n}$$

для любого $k \leq n$.

Доказательство. Для начала потребуется запись для $P(n, k)$ (доказательство корректности которой можно найти в учебнике Феллера "Теория вероятностей и ее приложения").

$$P(n, k) - A_k r_k^n = \sum_{j=1}^k B_{k,j} a_{k,j}^n,$$

где $A_k = r_k(r_k^{k+1} - p^{k+1}) / (r_k^{k+2} - (k+1)qp^{k+1})$, $B_{k,j} = a_{k,j}(p^{k+1} - a_{k,j}^{k+1}) / ((k+1)qp^{k+1} - a_{k,j}^{k+2})$, та же техника применялась в статьях [4] для вычисления производящих функций.

$a_{k,j}$ являются корнями многочлена $z^{k+2} - z^{k+1} + (1-p)p^{k+1} = 0$. Несложно видеть, что $|a_{k,j}| < 2p / ((k+1) - p(k+2))$. Тогда получаем следующую оценку:

$$|P(n, k) - A_k r_k^n| \leq 2kp^{k+1} / ((k+1) - (k+2)p).$$

Рассмотрим $k_1 = \log n / \log p - \log(\log n / pq) / |\log p| > 2p/q$. При $k > k_1$ данное ограничение позволяет упростить предыдущую оценку до удобного вида:

$$|P(n, k) - A_k r_k^n| \leq 2p^{n+1}q.$$

Оценим следующую величину $|A_k r_k^n - e^{-qp^{k-\log n/\log p}}|$.

Заметим, что данный модуль не превосходит $|\log A_k + n \log r_k - nqp^{k+1}|$ (здесь используется неравенство $|e^{-x} - e^{-y}| \leq |x - y|$).

Для получения требуемой оценки рассмотрим $n \log r_k + nqp^{k+1}$. Учитывая, что r_k является корнем уравнения $z^{k+2} - z^{k+1} + qp^{k+1} = 0$ и используя теорему Лагранжа об обращении [11], получаем следующее:

$$-\log r_k = \sum_{m=1}^{\infty} \frac{1}{m} \binom{mk + 2m - 1}{m - 1} (qp^{k+1})^m = qp^{k+1} + \epsilon.$$

С помощью формулы Стирлинга оценим ϵ :

$$\epsilon = \sum_{m=2}^{\infty} \frac{1}{m} \binom{mk + 2m - 1}{m - 1} (qp^{k+1})^m \leq \sum_{m=2}^{\infty} \frac{e^{m-1} (k+2)^{m-1}}{m} (qp^{k+1})^m < (k+2) q^2 p^{2(k+1)}.$$

Вернемся к определению $A_k = r_k(r_k^{k+1} - p^{k+1})/(r_k^{k+2} - (k+1)qp^{k+1})$. Пользуясь грубой оценкой сверху $A_k < 3r^{k+2}$ и оценкой на r_k , получаем следующее: $\log A_k \leq 3(k+2) \log^2 n/n$, т.е. $\log A_k = O(\log^3 n/n)$ (т.к. $qp^{k+1} \leq \log n/n$ при $k > k_1$).

Собирая все утверждения вместе, получаем требуемое при $k > k_1$.

При $k \leq k_1$ используем оценку:

$$|P(n, k) - e^{-qp^{k-\log n/\log p}}| \leq \max(P(n, k_1), e^{-qp^{k_1-\log n/\log p}}) = O(1/n).$$

Таким образом, получена равномерная на k оценка для $|P(n, k) - e^{-qp^{k-\log n/\log p}}|$ при достаточно большом n . $\square$

Теперь перейдем к оценкам для математического ожидания и дисперсии.

Теорема 6. Для случайной величины с функцией распределения $F_\xi = e^{-qp^{k-\log n/\log p}}$ имеем:

$$\begin{aligned} \mathbb{E}(\xi) &= \log n/|\log p| + \gamma/|\log p| - \log q/\log p - 1/2 + \alpha, \text{ где } |\alpha| \leq 2 * 10^{-6} \\ \text{Var}(\xi) &= \frac{1}{12} + \frac{\pi^2}{6 \log^2 q} + \beta, \text{ где } \beta < 10^{-6}. \end{aligned}$$

Доказательство. Для поиска моментов случайной величины ξ воспользуемся разложением функции $f(a) = \sum_{k=-\infty}^{\infty} (k-a)(F_\xi(k-a) - F_\xi(k-a-1))$ в ряд Фурье, где коэффициенты разложения удовлетворяют следующему равенству: $a_n = \int_{-\infty}^{\infty} t(F_\xi(t) - F_\xi(t-1)) \exp(zt) dt = \psi_n(z)$ в точке $z = 2\pi n t$.

Интегрируя, получаем, что $\psi_n(z) = (1 - e^z)e^{(\log p/\log q + 1)z}\Gamma(z - z \log p/\log q)$, а следовательно $a_n = \frac{d^n}{dx^n}\psi_n(x)$ в точке $x = 2\pi in$.

Учитывая, что $\Gamma'(1) = -\gamma$ и $\Gamma''(1) = \gamma^2 + \frac{\pi^2}{6}$, получаем:

$$a_0 = \gamma/|\log p| - \log p/\log q + 3/2.$$

$$a_1 = -1/|\log p|\Gamma(-2\pi in)\exp(-2\pi in(\log p/\log q + 1)).$$

Получаем, что $\mathbb{E}(\xi) = \log n/|\log p| + f(\log n/|\log p|) = \log n/|\log p| + a_0 + \alpha$.

Аналогичные рассуждения для дисперсии позволяют получить следующее $Var(\xi) = \frac{1}{12} + \frac{\pi^2}{6(\log p)^2} + \beta$. $\square$

Таким образом, показано, что Var_{L_n} ограничена константой. Более точные результаты для математического ожидания и дисперсии можно найти в [9].

5 Симуляции

Проведем численные вычисления, чтобы убедиться в точности результатов теорем.

Сначала рассмотрим вопрос поведения случайной величины L_n .

Графики на рис.1 демонстрируют зависимость частоты от длины последовательности. Параметры выборки $p = 0.5, 0.7$, $n = 30$.




Рис. 1: Зависимости L_n от $p = 0.5, 0.7$ при $n = 30$. Сплошная линия - симуляции, треугольники - рекуррентной формулы.

Из приведенных выше графиков видно, что при малом n значения L_n существенно отличаются от результатов расчетов по рекуррентным формулам. В случае $n = 1000$ расхождений практически нет (см. Рис. 2)




Рис. 2: Зависимости L_n от $p = 0.5, 0.7$ при $n = 1000$. Сплошная линия - симуляции, треугольники - рекуррентной формулы.

Перейдем к функции распределения $P(n, k)$. На рисунке 3 представлена кривая зависимости $P(n, k)$ от k и кривая $\exp(k - \log n / \log p)$. Как видно из графика при $n = 50$ эти графики почти совпадают.




Рис. 3: Зависимости $P(n, k)$ и $\exp(k - \log n / \log p)$ от $p = 0.5, 0.7$ при $n = 50$

Список литературы

- [1] *P.Erdős, P.Revesz*, On the length of the longest head-run, *Topics in information theory.*, **16**, (1975), 219-228.
- [2] *G. Bateman*, On the Power Function of the Longest Run as a Test for Randomness in a Sequence of Alternatives, *Biometrika.*, **35**, (1948), 97-112.
- [3] *L.Gordon, M.F.Schilling, M.S.Waterman*, An extreme value theory for long head runs, *Probability Theory and Related Fields.*, **72**, (1986), 279–287.
- [4] *L.Guibas, M.Odlyzko*, Long repetitive patterns in random sequences, *Zeitschrift für Wahrscheinlichkeitstheorie und Verwandte Gebiete.*, **53**, (1980), 241–262.
- [5] *J.Turi*, Limit theorems for the longest run, *Annales Mathematicae et Informaticae.*, **36**, (2009), 133-141.
- [6] *P.Erdős, A.Rényi*, On a new law of large numbers, *Journal d'Analyse Mathématique.*, **23**, (1970), 103-111.
- [7] *A.Földes*, The limit distribution of the length of the longest head-run, *Periodica Mathematica Hungarica.*, **10**, (1979), 301-310.
- [8] *I.Fazekas, Z.Karacsony, Z.Libor*, Longest runs in coin tossing, Comparison of recursive formulae, asymptotic theorems, computer simulations, *Acta Univ. Sapientiae, Mathematica.*, **2**, (2010), 215-228.
- [9] *M.Shilling*, The longest run of heads, *College Math. J.*, **21**, (1990), 196-207.
- [10] *Феллер*, Теория вероятностей и ее приложения, *Издательство "Мир"*, **1**, (1984), 297.
- [11] *E.Copson*, Theory of Functions of a Complex Variable, *Oxford university press.*, (1935).