

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ
УНИВЕРСИТЕТ

имени М.В.Ломоносова
механико-математический факультет

**Оценка длины наибольшей общей
подстроки в RLE-последовательностях
для процессов со счетным носителем**

Курсовая работа
студента 5-го курса 509-ой группы
кафедры теории вероятностей
Мударисова Тимура Маратовича

Научный руководитель
доктор физико-математических наук, профессор
Булинский Александр Вадимович

Москва, 2021 г.

Содержание

1	Введение	2
2	Постановка задачи	3
3	Случай счетного распределения	9
	Литература	12

1 Введение

Задача поиска схожестей в различных последовательностях часто встречается в разных разделах науки: генетике, теории вероятностей, теории информации и информатике. Развитие компьютерных методов способствует появлению новых алгоритмов сжатия данных и их дальнейшему изучению. Так, например, согласно расчетам ученых Швейцарской высшей технической школы Цюриха [9] один грамм ДНК может содержать в себе 455 эксабайтов ($\sim 4.5 \times 10^{20}$ байт) информации. Учитывая, что в среднем на раскодирование 83 килобайтов информации необходимо около 1000\$, возникает необходимость в изучении методов сжатия информации. Первый алгоритм сжатия данных – *Алгоритм Шеннона-Фано* – был предложен Клодом Шенноном [1], и им же были заложены основы данного направления. С тех пор были придуманы многие другие методы сжатия данных: *Алгоритм Хаффмана*, *Алгоритм Лемпеля-Зива-Уэлша* и многие другие. Широко известен и применим *Run-Length Encoding* алгоритм (далее RLE). Его суть заключается в следующем: рассмотрим, например, последовательность $s = \underbrace{1111}_4 \underbrace{222}_3 \underbrace{111}_3 \underbrace{33333}_5$, тогда $f_{RLE}(s) = (1, 4), (2, 3), (1, 3), (3, 5)$, таким образом вместо хранения всей последовательности достаточно знать сколько повторений символов в ней встречается. Предложенный метод сжатия часто встречается в различных задачах биологии [4], теории информации и теории вероятностей [6], [8]. В данной работе изучено асимптотическое поведение длины наибольшей общей подстроки последовательности, полученной RLE сжатием. В главе 3 показана связь данной величины с энтропией Renyi для случайных процессов, имеющих счетный носитель и обладающих свойством сильно-экспоненциального перемешивания.

2 Постановка задачи

Рассмотрим произвольный стационарный в узком смысле случайный процесс $(X_n)_{n \in \mathbb{N}}$, определенный на не более чем счетном алфавите $\mathcal{A}$. Пусть x и y – две независимые реализации процессов X и Y , при этом $X \stackrel{d}{=} Y$. Определим следующую величину:

Опр. Длиной наибольшей общей подстроки двух последовательностей $\{x_i\}_i$ и $\{y_i\}_i$ называется

$$M_n(x, y) = \max\{k : x_{i, \dots, i+k-1} = y_{j, \dots, j+k-1} \text{ для некоторых } 0 \leq i, j \leq n - k\}.$$

Изучением данной величины занимались P.Erdos, A.Renyi и многие другие математики. R.Arratia и M.Waterman в работе [3] показали, что для конечных марковских цепей выполнено следующее: $\lim_{n \rightarrow +\infty} \frac{M_n}{\log_{1/p} n} \rightarrow 2$, где p – наибольшее собственное значение матрицы переходных вероятностей. Данный результат был расширен в работе [11], где авторы исследовали процессы следующего вида:

Опр. Случайный процесс $(X_t)_{t \in \mathbb{R}}$, определенный на вероятностном пространстве $(\Sigma, \mathcal{F}, \mathbb{P})$, обладает свойством *сильного перемешивания* [2], если существует такая функция $\alpha : \mathbb{R} \rightarrow \mathbb{R}$, которая обладает следующими свойствами:

1. $\lim_{s \rightarrow +\infty} \alpha(s) = 0$
2. $\sup_{A \in \mathcal{F}_{-\infty}^t, B \in \mathcal{F}_{t+s}^{+\infty}} |\mathbb{P}(A \cap B) - \mathbb{P}(A)\mathbb{P}(B)| \leq \alpha(s)$, где $\mathcal{F}_a^b = \sigma(X_i, a \leq i \leq b)$ и

равенство выполнено для любого $t \in \mathbb{R}$.

Если при этом $\alpha(s)$ убывает экспоненциально, то говорят, что $(X_t)_{t \in \mathbb{R}}$ обладает свойством *сильно-экспоненциального перемешивания*.

Для процессов данного вида J.Rousseau [10] показал связь скорости сходимости величины M_n с энтропией Реньи.

Опр. Нижними и верхними энтропийными скоростями порядка 2 называются следующие величины:

$$\underline{H}_2(\mathbb{P}) = - \lim_{k \rightarrow +\infty} \frac{1}{k} \log_2 \left(\sum_{C_k} \mathbb{P}^2(C_k) \right) \text{ и } \bar{H}_2(\mathbb{P}) = - \overline{\lim}_{k \rightarrow +\infty} \frac{1}{k} \log_2 \left(\sum_{C_k} \mathbb{P}^2(C_k) \right),$$

где суммирование ведется по всем k -элементным строчкам из алфавита $\mathcal{A}$, т.е. если $C_k = \alpha_1 \dots \alpha_k$, то $\mathbb{P}(C_k) = \prod_{i=1}^k \mathbb{P}(\alpha_i)$. Если оба предела существуют, то их общее значение называют энтропийной скоростью порядка 2 и обозначают $H_2(\mathbb{P})$.

До сих пор не доказано существование данной величины в случае произвольного случайного процесса. Однако, было показано, что в случае марковских цепей [5] и процессов со свойством сильного перемешивания [6] оба предела существуют. Надо заметить, что даже в этих случаях доказательства были крайне сложными и авторы использовали алгебраические методы (например, теорию Перрона - Фробениуса).

Рассмотрим $(\Omega, \mathcal{F}, \mathbb{P})$, где $\Omega = \mathcal{A}^{\mathbb{N}}$, $|\mathcal{A}| < \infty$, $\mathcal{F}$ — сигма-алгебра, порожденная всеми строками из Ω . Определим понятие RLE-энкодера:

Опр. Рассмотрим алфавит $\mathcal{B} = \mathcal{A} \times \mathbb{N}$. $f : \mathcal{A}^{\mathbb{N}} \rightarrow \mathcal{B}^{\mathbb{N}}$, определенная по правилу: $f(\underbrace{a_1 \dots a_1}_{k_1} \underbrace{a_2 \dots a_2}_{k_2} \dots) = (a_1, k_1)(a_2, k_2) \dots$, называется *RLE - энкодером*.

Определим следующую вероятностную меру: $f_*\mathbb{P}((a, k)) = \mathbb{P}(f^{-1}((a, k)))$, т.е. это вероятность $\mathbb{P}(\underbrace{a \dots a}_k)$.

Длиной наибольшей общей подстроки последовательностей, полученных RLE-сжатием, будем называть величину:

$$M_n^f(x, y) = \max\{k : f(x)_{i, \dots, i+k-1} = f(y)_{j, \dots, j+k-1} \text{ для некоторых } 0 \leq i, j \leq n - k\},$$

где под равенством подразумевается следующее:

$$(x_i, q_i) \dots (x_{i+k-1}, q_{i+k-1}) = (y_j, m_j) \dots (y_{j+k-1}, m_{j+k-1}) \iff$$

$$\forall r \in \overline{[0, k-1]} : x_{i+r} = y_{j+r} \text{ и } q_{i+r} = m_{j+r}.$$

В работе [9] авторы доказали следующую теорему:

Теорема 1. *Рассмотрим $(\Omega, \mathcal{F}, \mathbb{P})$, где $\Omega = \mathcal{A}^{\mathbb{N}}$, $\mathcal{F}$ — сигма-алгебра, порожденная всеми строками из Ω , $\mathbb{P}$ — стационарная мера. Пусть f — RLE-энкодер. Тогда для почти всех $(x, y) \in \Omega \times \Omega$ выполнено:*

$$\overline{\lim}_{n \rightarrow +\infty} \frac{M_n^f(x, y)}{\log n} \leq \frac{2}{\underline{H}_2(f_*\mathbb{P})}.$$

Если при этом $\forall C_n \in \mathcal{F}_0^n$ выполнено, что $f^{-1}(C_n) \in \mathcal{F}_0^{h(n)}$, где $h(n) = o(n^\gamma)$, $\gamma > 0$, то для почти всех $(x, y) \in \Omega \times \Omega$ выполнено:

$$\underline{\lim}_{n \rightarrow +\infty} \frac{M_n^f(x, y)}{\log n} \geq \frac{2}{\bar{H}_2(f_*\mathbb{P})}.$$

И, если оба предела существуют и совпадают, то:

$$\lim_{n \rightarrow +\infty} \frac{M_n^f(x, y)}{\log n} = \frac{2}{H_2(f_*\mathbb{P})}.$$

В данной теореме присутствует довольно сильное допущение о том, что $f^{-1}(C_n) \in \mathcal{F}_0^{h(n)}$. J.Rousseau показал [10], что данный результат верен без этого допущения для процессов более узкого вида:

Теорема 2. *Если стационарный процесс обладает свойством сильно-экспоненциального перемешивания, то почти для всех (x, y) выполнено:*

$$\lim_{n \rightarrow +\infty} \frac{M_n^f(x, y)}{\log n} = \frac{2}{H_2(f_*\mathbb{P})}.$$

Доказательство данных теорем в работе не приводится. Однако стоит отметить, что оно крайне техническое и состоит в том, что явно строится номер, начиная с которого разность левой и правой части становится меньше ε . Приведем пример использования данной теоремы.

Пример 1. *Конечный марковский процесс.*

Пусть заданы алфавит $\mathcal{A} = \{a_i\}_{i=1}^N$, матрица переходных вероятностей $P = (p_{i,j})_{1 \leq i,j \leq N}$ и марковский процесс X , определенный на $\mathcal{A}$, с матрицей переходных вероятностей P . Чтобы применить предыдущие теоремы, надо найти $H_2(\mu)$, где μ – стационарная мера марковского процесса.

Заметим, что $f(X)$ тоже будет марковским процессом, определенным на алфавите $\mathcal{B} = \{(a, k)\}$ с некоторой матрицей переходных вероятностей $Q = (q_{(a_i,k),(a_j,l)})$ и начальным распределением ν . В самом деле, т.к. двух последовательных пар (a_i, k_i) с одной буквой быть не может:

$$\mathbb{P}(f(X)_{n+1} = (a_i, l) | f(X)_n = (a_i, k)) = 0$$

$$\mathbb{P}(f(X)_{n+1} = (a_i, l) | f(X)_n = (a_i, k), f(X)_{i_1} = (a_{i_1}, k_{i_1}) \dots f(X)_{i_t} = (a_{i_t}, k_{i_t})) = 0$$

В общем случае имеем:

$$\begin{aligned} \mathbb{P}(f(X)_{n+1} = (a_i, l) | f(X)_n = (a_j, k), f(X)_{i_1} = (a_{i_1}, k_{i_1}) \dots f(X)_{i_t} = (a_{i_t}, k_{i_t})) = \\ \mu(\underbrace{a_{i_1} \dots a_{i_1}}_{k_{i_1}} \dots \underbrace{a_i \dots a_i}_{l} \bar{a}_i) \cdot \mu^{-1}(\underbrace{a_{i_1} \dots a_{i_1}}_{k_{i_1}} \dots \underbrace{a_j \dots a_j}_{k} \bar{a}_j) = \frac{(1 - p_{i,i})p_{i,j}p_i^{l-1}}{1 - p_{j,j}} = \\ \mu(\underbrace{a_j \dots a_j}_{k} \underbrace{a_i \dots a_i}_{l} \bar{a}_i) \cdot \mu^{-1}(\underbrace{a_i \dots a_i}_{l} \bar{a}_i) = \mathbb{P}(f(X)_{n+1} = (a_i, l) | f(X)_n = (a_j, k)), \end{aligned}$$

где $\bar{a}_i, \bar{a}_j$ – любой элемент алфавита не равный a_i и a_j соответственно.

Используя предыдущие выкладки, получаем, что:

$$q_{(a_i,k),(a_i,l)} = \mathbb{P}(f(X)_{n+1} = (a_i, l) | f(X)_n = (a_i, k)) = 0,$$

$$q_{(a_i,k),(a_j,l)} = \mathbb{P}(f(X)_{n+1} = (a_j, l) | f(X)_n = (a_i, k)) = \frac{p_{i,j}p_{j,j}^{l-1}(1 - p_{j,j})}{1 - p_{i,i}}.$$

Начальное же распределение выглядит так:

$$\nu((a_i, k)) = \mathbb{P}(f(X)_1 = (a_i, k)) = \mu(a_i)p_{i,i}^{k-1}(1 - p_{i,i}).$$

Воспользуемся теоремой 2 из [7].

Теорема (G. Ciuperca [7]). Пусть $(Y)_{n \in \mathbb{N}}$ – марковский процесс, определенный на счетном пространстве состояний E . Пусть $Q = (q(i, j))_{(i, j) \in E^2}$ и начальное распределение $\pi = (\pi(i))_{i \in E}$. Если выполнены следующие условия:

1. $\sup_{(i, j) \in E^2} q(i, j) < 1$
2. $\exists \sigma_0 < 1$: для любого $s > \sigma_0$

$$\sup_{i \in E} \sum_{j \in E} q(i, j)^s < \infty$$

3. $\forall \varepsilon > 0$ и $s > \sigma_0$, существует $A \subset E$ с конечным числом элементов, что

$$\sup_{i \in E} \sum_{j \in E \setminus A} q(i, j)^s < \varepsilon,$$

Тогда верно:

$$H_2(\mathbb{P}) = -\log \lambda,$$

где λ – наибольшее собственное значение матрицы Q .

Для использования данного результата надо проверить ряд условий.

1. Ограничение супремума $q(i, j)$ единицей:

$$\sup_{1 \leq i, j \leq N} q_{(a_i, k), (a_j, l)} = \sup_{1 \leq i, j \leq N} \frac{p_{i, j} p_{j, j}^{l-1} (1 - p_{j, j})}{1 - p_{i, i}} \leq \sup_{1 \leq i \leq N} (1 - p_{i, i}) < 1.$$

2. Ограничение супремума суммы $\sum_{i, j} q^s(i, j)$:

$$\sup_{1 \leq i \leq N} \sum_{1 \leq j \leq N, l \in \mathbb{N}} q_{(a_i, k), (a_j, l)}^s = \sup_{1 \leq i \leq N} \sum_{1 \leq j \leq N} \left(\frac{p_{i, j} (1 - p_{j, j})}{1 - p_{i, i}} \right)^s \frac{1}{1 - p_{j, j}^s} < +\infty.$$

3. $\forall \varepsilon > 0$ существует $A = \{(a_i, k)\}$, что $\sup_{j \in \mathcal{B}} \sum_{e \notin A} q^s(j, e) < \varepsilon$.

Введем $M = \sup_{1 \leq i \leq N} \sum_{1 \leq j \leq N} \left(\frac{p_{i,j}(1 - p_{j,j})}{1 - p_{i,i}} \right)^s$. В силу того, что $p_{i,j} < 1$, существует $m \in \mathbb{N}$: $\frac{p_{j,j}^{ms}}{1 - p_{j,j}^s} < \frac{\varepsilon}{M}$. Значит:

$$\sup_{1 \leq i \leq N, k \in \mathbb{N}} \sum_{(a_j, l) \in \mathcal{B} - A} q_{(a_i, k), (a_j, l)}^s = \sup_{1 \leq i \leq N} \sum_{1 \leq j \leq N} \left(\frac{p_{i,j}(1 - p_{i,i})}{(1 - p_{j,j})} \right)^s \frac{p_{j,j}^{ms}}{1 - p_{j,j}^s} < \varepsilon,$$

где $A = \{(a_i, k)\}_{1 \leq k < m}$. Таким образом, условия теоремы 2 из [7] выполняются и $H_2(\mathbb{P}) = -\log \lambda$, где λ - наибольшее собственное значение матрицы $Q = (q_{(a_i, k), (a_j, l)})_{1 \leq i, j \leq N}$.

Заметим, что несмотря на конечность носителя процесса X , данный пример не является очень простым. В случае счетного носителя вычисления для конкретного процесса будут еще сложнее. Поэтому возникает необходимость в поиске универсального способа подсчета для процессов со счетным носителем.

3 Случай счетного распределения

Найдем асимптотическое поведение величины $H_2(\mathbb{P})$ для процессов, удовлетворяющих условиям теоремы 2 и имеющих счетный носитель. Для начала докажем следующую техническую лемму:

Лемма 1. Пусть даны два числовых ряда $S_1 = \sum_{i=1}^{+\infty} \left[\frac{1}{1-a_i^2} - 1 \right]$ и $S_2 = \sum_{i=1}^{+\infty} a_i^2$, где $\forall i : 0 \leq a_i < 1$. Тогда, если ряды сходятся, то выполнено: $S_1 \geq S_2$.

Доказательство. Заметим, что нам достаточно показать, что

$$\frac{1}{1-a_i^2} - 1 \geq a_i^2 \iff 1 \geq 1 - a_i^4,$$

что верно $\forall a_i$. □

Рассмотрим следующий счетный алфавит $\mathcal{A} = \{a_1, \dots, a_n, \dots\}$. Также определим $\mathcal{B} = \mathcal{A} \times \mathbb{N}$.

Теорема 3. Пусть $(X)_n$ – процесс, определенный на $(\mathcal{A}, \mathcal{A}^{\mathbb{N}}, \mathbb{P})$ и удовлетворяющий условиям теоремы 2, тогда верно:

$$H_2(\mathbb{P}) = -\log \left(\frac{a + \sqrt{a^2 + 4(b-a)}}{2} \right),$$

где

$$a = \sum_{i=1}^{+\infty} \left[\frac{1}{1 - \mathbb{P}^2(X=i)} - 1 \right] \tag{1}$$

$$b = \sum_{i=1}^{+\infty} \mathbb{P}^2(X=i) \tag{2}$$

Доказательство. Рассмотрим $\tilde{C}_n = (a_{i_1}, k_1), (a_{i_2}, k_2), \dots, (a_{i_n}, k_n)$. Найдем вероятность прообраза $f^{-1}(\tilde{C}_n) = \underbrace{a_{i_1} \dots a_{i_1}}_{k_1} \dots \underbrace{a_{i_n} \dots a_{i_n}}_{k_n}$. Обозначим $p_n = \sum_{\tilde{C}_n} \mathbb{P}^2(f^{-1}(\tilde{C}_n))$.

Легко видеть, что $\{\tilde{C}_n\} = \{\tilde{C}_{n-1}\} \times \{(a_{i_n}, k_n), a_{i_n} \in \mathcal{A} \setminus a_{i_{n-1}}, k_n \in \mathbb{N}\}$. Таким образом, можно редуцировать подсчет данной суммы к случаю p_{n-1} .

Заметим, что основная проблема подсчета p_n в том, что $a_{i_j} \neq a_{i_{j+1}}$. Разрешим повторения в конце последовательности и затем вычтем те случаи, когда повторения случались. Таким образом получим:

$$p_n = p_{n-1} \cdot \sum_{k_n=1}^{+\infty} \sum_{i=1}^{+\infty} \mathbb{P}^{2k_n}(X=i) - \mathbb{P}(\{(a_{i_1}, k_1) \dots (a_{i_{n-1}}, k_{n-1}), (a_{i_{n-1}}, k_n)\}).$$

Преобразуем слагаемые по-отдельности:

$$1. \sum_{k_n=1}^{+\infty} \sum_{i=1}^{+\infty} \mathbb{P}^{2k_n}(X=i) = \sum_{i=1}^{+\infty} \sum_{k_n=1}^{+\infty} \mathbb{P}^{2k_n}(X=i) = \sum_{i=1}^{+\infty} \left[\frac{1}{1 - \mathbb{P}^2(X=i)} - 1 \right].$$

2. Пусть $c_{n-1} = \mathbb{P}(\{(a_{i_1}, k_1) \dots (a_{i_{n-1}}, k_{n-1}), (a_{i_{n-1}}, k_n)\})$. Заметим, что на самом деле эта же вероятность равна следующему: $\mathbb{P}(\{(a_{i_1}, k_1) \dots (a_{i_{n-1}}, k_{n-1} + k_n)\})$. Т.к. $k_{n-1}, k_n \in \mathbb{N}$, тогда $k_{n-1} + k_n \geq 2$. Т.е. данная вероятность есть в действительности $p_{n-1} - \mathbb{P}(\{(a_{i_1}, k_1) \dots (a_{i_{n-2}}, k_{n-2}), (a_{i_{n-1}}, 1)\})$.

Заметим, что последнее слагаемое имеет уже известную нам структуру:

$$c_{n-1} = p_{n-1} - \sum_{i=1}^{+\infty} \mathbb{P}^2(X=i) p_{n-2} + c_{n-2}.$$

Опять же допустим, что равенство выполнено, а затем вычтем лишние случаи и воспользуемся тем, что $k_{n-1} + 1 \geq 2$. Рассмотрим равенства (1) и (2). Несложно

видеть, что $a > b$, что верно в силу Леммы 1. Таким образом, получаем следующие рекуррентные соотношения:

$$p_n = a \cdot p_{n-1} - c_{n-1},$$

$$c_n = p_n - b \cdot p_{n-1} + c_{n-1} = (a - b) \cdot p_{n-1}$$

с начальными данными: $p_0 = 1$, $c_1 = 1$ - это всего лишь $\sum_i \mathbb{P}(a_i) = 1$. Заметим, что $p_n - p_{n-1} = (ap_{n-1} - c_{n-1}) - (ap_{n-2} - c_{n-2}) = a(p_{n-1} - p_{n-2}) - (p_{n-1} - bp_{n-2})$, следовательно, выражая p_n из последнего равенства получаем:

$$p_n = ap_{n-1} + (b - a)p_{n-2}.$$

Этому рекуррентному соотношению соответствует следующее характеристическое уравнение $x^2 - ax - (b - a) = 0$. В самом деле, линейному рекуррентному соотношению вида $p_n = a_1p_{n-1} + \dots + a_dp_{n-d}$ соответствует характеристическое уравнение $x^d - a_1x^{d-1} - \dots - a_dx - a_d = 0$. Значит $x_{1,2} = \frac{a \pm \sqrt{a^2 + 4(b - a)}}{2}$. Тогда $p_n = C_1x_1^n + C_2x_2^n$. Учитывая начальные условия, получаем, что

$$p_n = \frac{1}{2^{n+1}} \cdot \left((a - \sqrt{a^2 + 4(b - a)})^n + (a + \sqrt{a^2 + 4(b - a)})^n \right) + \\ + \frac{1}{2^{n+1}} \cdot \left(a \frac{(a + \sqrt{a^2 + 4(b - a)})^n - (a - \sqrt{a^2 + 4(b - a)})^n}{\sqrt{a^2 + 4(b - a)}} \right).$$

Осталось выделить главный член данной последовательности:

$$a + \sqrt{a^2 + 4(b - a)} \geq a - \sqrt{a^2 + 4(b - a)},$$

следовательно, получаем, что $p_n \sim \frac{(a + \sqrt{a^2 + 4(b - a)})^n}{2^{n+1}} \cdot \left(1 + \frac{a}{\sqrt{a^2 + 4(b - a)}} \right)$.

$$\text{Тогда } H_2(\mathbb{P}) = \lim_{n \rightarrow +\infty} -\frac{1}{n} \log(p_n) = -\log \left(\frac{a + \sqrt{a^2 + 4(b - a)}}{2} \right). \quad \square$$

Список литературы

- [1] *Shannon, C.E.*, A Mathematical Theory of Communication, *Bell System Technical Journal.*, **27**, (1948), 379-423.
- [2] *И.Ибрагимов, Ю.Линник*, Независимые и стационарно связанные величины, *Издательство "Наука"*, 388-389, (1965).
- [3] *R. Arratia, P. Morris and M. Waterman*, Stochastic scrabble: Large deviations for sequences with scores, *J. Appl. Prob.*, **25**, (1988), 106-119.
- [4] *M.S.Waterman*, Introduction to Computational Biology: , *Maps, Sequences and Genomes.*, **72**, (1995).
- [5] *Z.Rached*, Renyi's Entropy for Discrete Markov Sources., . *Master of Science Project*, (1998).
- [6] *I. Kontoyiannis, P. H. Algoet, Y. M. Suhov, A. J. Wyner*, Nonparametric Entropy Estimation for Stationary Processes and Random Fields, with Applications to English Text, *IEEE Trans. Inform. Theory.*, **44**, (1998), 1319-1327.
- [7] *G. Ciuperca, V. Girardin, L. Lhote.*, Computation and Estimation of Generalized Entropy Rates for Denumerable Markov Chains, *IEEE Trans. Inf. Theory.*, **57**, (2011).
- [8] *M.H.Neumann*, Absolute regularity and ergodicity of Poisson count processes, *Bernoulli*, **17**, (2011), 1268–1284.
- [9] *Dr. Robert N.Grass, Dr. Reinhard Heckel, M. Sc. Michela Puddu, M. Sc. Daniela Paunescu, Prof. Wendelin J. Stark*, Robust Chemical Preservation of Digital Information on DNA in Silica with Error-Correcting Codes, *Angewandte, Chemie.*, **54**, (2015).
- [10] *A. Coutinho, R. Lambert and J. Rousseau*, Matching strings in encoded sequences, *arXiv:1903.09625*, (2019).

- [11] *J.Rousseau*, Renyi entropy and pattern matching for length-encoded sequences, *arXiv:2003.05500*, (2020).