

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО
ОБРАЗОВАНИЯ «МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ
УНИВЕРСИТЕТ

имени М.В.ЛОМОНОСОВА»

МЕХАНИКО-МАТЕМАТИЧЕСКИЙ ФАКУЛЬТЕТ

КАФЕДРА ТЕОРИИ ВЕРОЯТНОСТЕЙ

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
(ДИПЛОМНАЯ РАБОТА)

специалиста

**СОСТОЯТЕЛЬНОСТЬ НЕЙРОСЕТЕВЫХ
ОЦЕНОК
УСЛОВНОЙ СОВМЕСТНОЙ
ИНФОРМАЦИИ**

Выполнил студент

609-ой группы

Мударисов Тимур Маратович

подпись студента

Научный руководитель:

доктор физико-математических наук, профессор

Булинский Александр Вадимович

подпись научного руководителя

Москва

2022

Содержание

1	Введение	2
2	Описание модели	3
3	Основные результаты	8
3.1	Предположения	8
3.2	Доказательство основных результатов	8
4	Компьютерные эксперименты	14
5	Сопоставление с предшествующими результатами	17
6	Выводы	19
	Литература	20

1 Введение

Модели нейронных сетей являются популярными. Они используются в задачах распознавания образов, прогнозирования, рекомендательных системах и т.д. В следующем разделе мы напомним основные определения теории нейронных сетей, используемые в нашей дипломной работе. Важными статьями в этой области являются работы [1] и [10]. Нейронные сети могут использоваться в разнообразных задачах. Так, в [11] исследовано, как с их помощью можно приближать различные величины. В теореме 2.2 данной статьи они показали, что нейронные сети с одним скрытым слоем аппроксимируют любую борелевскую функцию на прямой. Данный результат позволяет использовать нейросетевые модели для построения оценок различных величин.

В [17] и [18] авторы предложили несколько оценок условной взаимной информации с помощью нейросетевого классификатора. Условная взаимная информация (далее $I(X; Y|Z)$) и взаимная информация (далее $I(X; Y)$) – меры *схожести* между случайными величинами. Они весьма удобны в задачах понижения размерности данных и отбора значимых факторов (см. например [14], [3]). Известны также работы, где авторы изучают информацию пересечения и условную информацию пересечения, в английской литературе *interaction information* и *conditional interaction information* [16]. Данные величины обобщают понятия взаимной информации и условной взаимной информации на случай M случайных векторов. Однако, чаще используют $I(X; Y|Z)$. Например, в работе [7] автор показывает, как данную величину можно использовать для классификации изображений. В работах [17], [18] для построения оценок условной взаимной информации авторы применяют известное разложение Донскера-Варадана [5]. Данное представление также называется представлением Лежандра.

Оценки взаимной информации Реньи и условной взаимной информации Реньи были получены в [23] и [15]. Исследуемая в нашей работе величина аналогична той, которую изучали в указанных статьях. Особенностью оценок, полученных авторами [23], [15], является то, что они непараметрические. Несмотря на значимые теоретические результаты, полученные в упомянутых статьях, отметим, что для практического использования при компьютерном анализе данных более удобны оценки, предложенные в [17], [18].

Основным установленным результатом в [17], [18] является состоятельность оценок условной взаимной информации. Однако авторы не изучили важный вопрос L_2 - состоятельности и асимптотической несмещенности построенных оценок. Также ими не было произведено компьютерного моделирования в случае выборок из распределений, имеющих тяжелые хвосты.

Целью дипломной работы является исследование вопроса асимптотической нормальности и L_2 - состоятельности оценок, полученных в статьях [17], [18]. Компьютерное моделирование показало, что, в отличие от оценок [3], изучаемые нами оценки оказываются неэффективными для выборок, подчиняющихся закону Коши.

2 Описание модели

Рассмотрим $X \in \mathbb{R}^d$. Пусть $\mathcal{A} = \{Ax + b, A \in \mathbb{R}^{n \times m}, b \in \mathbb{R}^n\}$ – класс аффинных линейных преобразований вектора $x \mapsto Ax + b \in \mathbb{R}^n$. Линейной нейронной сетью будем называть функцию вида:

$$F_N(X) = A_N \circ f_{N-1} \circ A_{N-1} \circ \dots \circ f_1 \circ A_1(X), \quad (1)$$

где $N \in \mathbb{N}$, $f_i \in C(\mathbb{R}^{d_i})$, $A_i \in \mathcal{A}$. При этом f_i называются функциями активации, A_i – линейными слоями. На практике необязательно применяют такую структуру. В качестве слоев сети могут быть использованы не только аффинные преобразования, в качестве функций активации могут рассматриваться всевозможные удобные (для данной задачи) отображения, градиент которых легко вычислить. Популярность данных моделей была вызвана упомянутыми выше работами [1] и [10]. Отметим также [20], в которой автор описал знаменитую модель перцептрона. В статьях [1], [10] был продемонстрирован *принцип обратного распространения ошибки*. Суть этого принципа в правиле суперпозиции производной сложной функции:

$$\frac{dg(f(x))}{dx} = \nabla g(f(x)) \times f'(x). \quad (2)$$

Заметим, что данные функции могут быть функциями многих переменных. Таким образом, чтобы посчитать производную на определенном шаге построения нашей модели, нам надо знать градиент $\nabla g(f(x))$ (некоторой функции активации) и найденную ранее производную $f'(x)$. Данный результат означает, что можно использовать нейронные сети в различных градиентных методах оптимизации: в методе градиентного спуска, методе стохастического градиентного спуска и других (см., например, [21]). Это важно, поскольку на практике различные задачи машинного обучения сводятся к минимизации некоторого функционала. Как известно, минимизацию функционалов на практике удобно выполнять с помощью градиентных методов. Для нейронных сетей градиент, как показано в [1], [10], легко вычислим. Таким образом, благодаря принципу обратного распространения ошибок, нейросетевые модели используются весьма широко: обработка графики [13], переводчики [24], финансы [12], задачи прогнозирования [8] и т.д.

Далее будем рассматривать модель вида $F_3(X)$, называемую в англоязычной литературе *feed-forward networks*. Иначе говоря, это модель, состоящая из трех линейных слоев и двух одинаковых непрерывных функций активации. Математически ее можно записать как следующее семейство функций: $\{A_3 \circ f \circ A_2 \circ f \circ A_1\}$, где $f : \mathbb{R}^m \rightarrow \mathbb{R}^m$, $f \in C(\mathbb{R}^m)$, $A_3 : \mathbb{R}^m \rightarrow \mathbb{R}$, $A_2 : \mathbb{R}^m \rightarrow \mathbb{R}^m$, $A_1 : \mathbb{R}^r \rightarrow \mathbb{R}^m$, $m \in \mathbb{N}$. Далее обозначим класс таких функций как Σ_3 . Для моделей этого типа в статье [11] авторы доказывают следующий результат.

Теорема 1. *Пусть μ – вероятностная мера на $(\mathbb{R}^r, \mathcal{B}(\mathbb{R}^r))$, $r \in \mathbb{N}$. Тогда семейство Σ_3 , μ почти всюду плотно в пространстве борелевских функций.*

Под μ почти всюду плотностью авторы подразумевают, что для любой функции борелевской $f(x)$ существует $\tilde{F}(x) \in \Sigma_3$: $\tilde{F} = f$ почти всюду относительно меры μ . Иначе говоря, данная теорема утверждает, что для любой борелевской функции $g(x)$, определенной на $\mathbb{R}^r$, всегда существует нейронная сеть, которая приближает $g(x)$.

Введем понятие условной взаимной информации.

Определение 1 (см., например, [9], с. 40). *Пусть случайные векторы X, Y, Z – определены на одном вероятностном пространстве $(\Omega, \mathcal{F}, \mathbb{P})$ и имеют совместную плотность $p(x, y, z)$. Тогда условной взаимной информацией X и Y при условии Z называется следующая величина:*

$$I(X; Y|Z) = \int \int \int p(x, y, z) \log \frac{p(x, y, z)}{p(x|z)p(y, z)} dx dy dz, \quad (3)$$

где $p(x|z)$ – условная плотность X при условии Z , $p(y, z)$ – совместная плотность Y, Z .

Приведем несколько полезных свойств данной величины (доказательства можно найти в [19]):

- $I(X; Y|Z) \in [0, +\infty]$,
- $I(X; Y|Z) = I(X; Y, Z) - I(X; Z)$, где

$$I(X; Y) = \int \int p(x, z) \log \frac{p(x, z)}{p(x)p(z)} dx dz. \quad (4)$$

В работе [5] авторы доказывают важную теорему, которая позволяет задать условную взаимную информацию как минимум некоторого функционала.

Теорема 2. Пусть $X, Y, Z \in L_2(\Omega)$, и пусть величина $I(X; Y|Z)$ конечна. Тогда:

$$I(X; Y|Z) = \sup_{f(x,y,z) \in L_2} \left(\mathbb{E}_{p(x,y,z)} [f(x, y, z)] - \log \mathbb{E}_{p(x|z)p(y,z)} \left[e^{f(x,y,z)} \right] \right), \quad (5)$$

где $\mathbb{E}_{p(x,y,z)} [f(x, y, z)] = \int \int \int f(x, y, z) p(x, y, z) dx dy dz$. При этом равенство достигается на некоторой функции.

Замечание. Запись $X \in L_2(\Omega)$ означает, что конечен второй момент для каждой компоненты случайного вектора X .

Авторы в [1] показали, что теорема 2 допускает эквивалентную формулировку:

$$I(X; Y|Z) = \sup_{f(x,y,z) \in L_2} \left(\mathbb{E}_{p(x,y,z)} [f(x, y, z)] - e^{-1} \mathbb{E}_{p(x|z)p(y,z)} [e^{f(x,y,z)}] \right). \quad (6)$$

Таким образом, существует три способа задать условную взаимную информацию: (3), (5), (6).

В случае, когда плотности известны, можно явно выразить функцию f , на которой достигается равенство в (5) и (6). Однако на практике совместная плотность неизвестна и используются ее оценки по известной выборке.

Пусть S – подмножество объемлющего евклидова пространства $\mathbb{R}^D$. Рассмотрим выборку из N объектов $\{(X_k, Y_k, Z_k)\}$, $k = 1, \dots, N$, которая состоит из независимых одинаково распределенных векторов, имеющих плотность $p(x, y, z)$. Опишем алгоритм построения оценок условной взаимной информации, представленный в [17]. Далее для удобства обозначений пишем: $x^N = \{X_i\}_{i=1}^N$, $y^N = \{Y_i\}_{i=1}^N$, $z^N = \{Z_i\}_{i=1}^N$.

Определение 2. Пусть $u \in S$, $\tilde{Z} = \{z_{i_1}, \dots, z_{i_m}\}$ и задано $k \leq m$. Тогда k -м ближайшим соседом элемента u среди $\tilde{Z}$ будем называть такой элемент $\bar{z}$, для которого существует биективное $\pi_u : \{i_1, \dots, i_m\} \rightarrow \{i_1, \dots, i_m\}$:

$$\|u - z_{\pi_u(1)}\| \leq \dots \leq \|u - z_{\pi_u(k-1)}\| \leq \|u - \bar{z}\| \leq \|u - z_{\pi_u(k+1)}\| \dots \leq \|u - z_{\pi_u(m)}\|,$$

где $\|x\|$ обозначает евклидову норму элемента x .

Определение 3. Пусть J_b – множество b случайно выбранных индексов из $\{1, \dots, N\}$ (без возвращения). Обозначим $B_{joint}^b = \{(X_i, Y_i, Z_i) : i \in J_b\}$ часть выборки, соответствующую совместному распределению.

Рассмотрим $J_b^c = \{1, \dots, N\} \setminus J_b$, где J_b – множество b случайно выбранных индексов из $\{1, \dots, N\}$. Пусть $\tilde{Z} = \{Z_i \in z^N : i \in J_b^c\}$.

Определение 4. Пусть $u \in S$, обозначим $A^{N,b,k}(u, z^N)$ множество индексов k - ближайших соседей элемента u среди $\tilde{Z}$. Тогда $B_{product}^{b'} = \{(X_{j(i)}, Y_i, Z_i) : i \in J_b, j(i) \in A^{N,b,k}(z_i)\}$ – часть выборки, соответствующая условному распределению.

Для того чтобы получить оценки функции f , необходимо задать функционал, значение которого нейронная сеть будет минимизировать. Следуя [17], [18], дадим следующее определение:

Определение 5. Кросс-энтропийным минимизирующим функционалом будем называть:

$$L(w) = -\mathbb{E}_{p(q)p(x,y,z|q)} [q \log w(X, Y, Z) + (1 - q) \log(1 - w(X, Y, Z))], \quad (7)$$

где $w : S^3 \rightarrow \mathbb{R}$ и $q = \mathbb{I}\{(x, y, z) \in B_{joint}^b\}$.

Приведем важную лемму.

Лемма 1 (Lemma 2, [17]). Пусть $w_{\min} = \arg \min_w [L(w)]$ и пусть $p_1 = \mathbb{P}(q = 1)$. Тогда:

$$\Gamma(x, y, z) := \frac{1 - p_1}{p_1} \frac{w_{\min}}{1 - w_{\min}} = \frac{p(x, y, z)}{p(x|z)p(y, z)}. \quad (8)$$

Таким образом, видно, что минимизация данного функционала приводит к интересующему нас отношению плотностей. Однако математическое ожидание, фигурирующее в (8), зависит от неизвестной плотности, поэтому необходимо рассмотреть аппроксимирующий функционал, значение которого можно минимизировать, используя известную выборку. Обозначим за $w_\theta(x, y, z)$ результат работы нейронной сети для элементов (x, y, z) .

Определение 6. Эмпирическим кросс-энтропийным функционалом будем называть следующую величину:

$$L_{emp}(w) = -\frac{b}{b' + b} \sum_{(x,y,z) \in B_{joint}^b} \log w_\theta(x, y, z) - \frac{b'}{b + b'} \sum_{(x,y,z) \in B_{product}^{b'}} \log(1 - w_\theta(x, y, z)), \quad (9)$$

где $b = |B_{joint}^b|$, $b' = |B_{product}^{b'}|$. Под $|B|$ подразумевается мощность множества B .

Данный функционал уже не зависит от совместной плотности $p(x, y, z)$. Введем аналогичное выражение:

$$\hat{\Gamma}(x, y, z) := \frac{b'}{b} \frac{w_{\hat{\theta}}(x, y, z)}{1 - w_{\hat{\theta}}(x, y, z)}, \quad (10)$$

которое при достаточно большом числе параметров нейронной сети и высоком N сколь угодно близко к $\Gamma(x, y, z)$, что верно в силу теоремы 1. Обозначим за $Mat_{q \times q}(\mathbb{R})$ пространство вещественных квадратных матриц размерности q . Заметим, что при увеличении размерности m матрицы A_2 в определении Σ_3 мы рассматриваем матрицы, которые содержат своими диагональными подматрицами элементы $A_2(q)$, где $q < m$ и $A_2(q) = Mat_{q \times q}(\mathbb{R})$. Тем самым, если $\Phi' \in \Sigma_3$ приближает $\Gamma(x, y, z)$, то существует $\Phi'' \in \Sigma_3$ для которой верно:

1. Размерность промежуточного слоя m больше размерности q промежуточного слоя нейронной сети Φ' .
2. Φ'' также приближает $\Gamma(x, y, z)$.

Следовательно, теорема 1 совместно с теоремой Стоуна-Вейерштрасса [22] позволяет приближать борелевскую функцию $\Gamma(x, y, z)$ сколь угодно точно. Таким образом, в [17], [18] предложены оценки:

$$f_{DV}^* = \frac{1}{b} \sum_{(x,y,z) \in B_{joint}^b} \log \hat{\Gamma}(x, y, z) - \log \frac{1}{b'} \sum_{(x,y,z) \in B_{product}^{b'}} \hat{\Gamma}(x, y, z), \quad (11)$$

$$f_{NWJ}^* = 1 + \frac{1}{b} \sum_{(x,y,z) \in B_{joint}^b} \log \hat{\Gamma}(x, y, z) - \frac{1}{b'} \sum_{(x,y,z) \in B_{product}^{b'}} \hat{\Gamma}(x, y, z), \quad (12)$$

$$f_{LDR}^* = \frac{1}{b} \sum_{(x,y,z) \in B_{joint}^b} \log \hat{\Gamma}(x, y, z). \quad (13)$$

Здесь аббревиатуры означают следующее:

- LDR = Likelihood Density Ratio (соотв. (3)).
- DV = Donsker, Varadhan (соотв. (5)).
- NWJ = Nguyen, Wainwright, Jordan (соотв. (6)).

Как мы видим, каждому функционалу, фигурирующему в определениях (3), (5), (6), соответствует своя оценка.

3 Основные результаты

3.1 Предположения

В работах [17], [18] авторы показали, что при некоторых предположениях предложенные оценки являются состоятельными. Опишем условия, которые понадобятся далее.

1. Считаем, что $k > \tilde{C}n^{1/2+\epsilon}$, для некоторого $\epsilon > 0$. Также предполагаем, что $C_1 \leq \frac{b'(n)}{b(n)} \leq C_2$.
2. Для любого $(x, y, z) \in S^3$, допускаем, что $p(x, y, z)$ и $p(x|z)p(y, z) \in [\alpha, \beta]$, где $0 < \alpha < \beta < 1$.
3. Имеем $\theta \subset \mathbb{R}^l$ и $\|\theta\|_2 \leq K$, где θ – множество всех параметров нейросети. В данном случае $\theta = (A_1, b_1, A_2, b_2, A_3, b_3)$, где $A_1 \in \mathbb{R}^{n \times h}$, $A_2 \in \mathbb{R}^{h \times h}$, $A_3 \in \mathbb{R}^{h \times 1}$, $b_1 \in \mathbb{R}^{h \times 1}$, $b_2 \in \mathbb{R}^{h \times 1}$, $b_3 \in \mathbb{R}$ (т.е. в данном случае $l = nh + h^2 + 3h + 1$).
4. Считаем, что $w_\theta \in [\tau, 1 - \tau]$, где $0 < \tau < 1$. Это делается для возможности компьютерной обработки данных. Например, компьютер не способен проводить вычисления с числами вида 10^{-300} , он посчитает их за 0.
5. Пусть $I(X; Y|Z) \in [Q, +\infty)$, где $Q > 0$.

3.2 Доказательство основных результатов

Для доказательства нам понадобятся следующие два результата.

Лемма 2 (Theorem 1, [6]). Пусть $X_1, X_2, \dots$ – последовательность независимых одинаково распределенных случайных величин с $\mathbb{E}(X_1) = \nu$ и $\text{Var}(X_1) = \sigma^2 > 0$, для которой выполнена центральная предельная теорема:

$$\frac{\sqrt{n}(X_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1), n \rightarrow \infty, \quad (14)$$

где d обозначает сходимость по распределению. Пусть $g(x)$ – некоторая гладкая функция. Тогда, если $g'(\mu) \neq 0$, выполнено следующее:

$$\frac{\sqrt{n}(g(X_n) - g(X))}{|g'(\mu)|\sigma} \xrightarrow{d} N(0, 1), n \rightarrow \infty. \quad (15)$$

Лемма 3 (Lemma 6, [18]). Для любого $\epsilon > 0$, существует число η такое, что:

$$|L(\gamma_1) - L(\gamma_2)| < \epsilon \Rightarrow \|\gamma_1 - \gamma_2\|_1 < \eta, \quad (16)$$

где $L(x)$ – функционал, определенный по формуле (7), а $\eta = (1-\tau)\sqrt{2\lambda(S)}\epsilon$.

Перейдем к основному нашему результату.

Теорема 3. Пусть выполнены условия (1) – (5), предположим также, что $X, Y, Z \in L_2(\Omega)$, тогда $f_{DV}^*, f_{LDR}^*, f_{NWJ}^*$ состоятельны в L_2 смысле.

Доказательство.

1°. Начнем с f_{LDR}^* . Положим $p = p(x, y, z)$, а $q = p(x|z)p(y, z)$. Имеем:

$$\begin{aligned} \mathbb{E}_p [f_{LDR}^* - I(X; Y|Z)]^2 &= \mathbb{E}_p \left[f_{LDR}^* - \mathbb{E}_p \log \hat{\Gamma}(X, Y, Z) + \right. \\ &\quad \left. \mathbb{E}_p \log \hat{\Gamma}(X, Y, Z) - I(X; Y|Z)^2 \right] \leq \\ &2 \left(\mathbb{E}_p \left[f_{LDR}^* - \mathbb{E}_p \log \hat{\Gamma}(X, Y, Z) \right]^2 + \mathbb{E}_p \left[I(X; Y|Z) - \mathbb{E}_p \log \hat{\Gamma}(X, Y, Z) \right]^2 \right) =: \\ &2(I_1 + I_2). \end{aligned}$$

Рассмотрим слагаемые по отдельности. Для I_1 воспользуемся леммой 2 при $g(x) = \log x$. Тогда

$$I_1 = \mathbb{E}_p \left[\frac{1}{b} \sum_{(x,y,z) \in B_{joint}^b} (\log \hat{\Gamma}(x, y, z) - \mathbb{E}_p \log \hat{\Gamma}(X, Y, Z)) \right]^2 \asymp \frac{\text{Var}(\hat{\Gamma}(X, Y, Z))}{b[\mathbb{E}(\hat{\Gamma}(X, Y, Z))]^2},$$

где для числовых последовательностей (u_n) и (v_n) , где $v_n \neq 0$, знак $\asymp$ означает, что найдутся $c_1, c_2 > 0$ такие, что $c_1 \leq \frac{u_n}{v_n} \leq c_2$ при всех $n \in \mathbb{N}$.

Согласно (10), $\hat{\Gamma}(X, Y, Z) = \frac{b'}{b} \frac{w_{\hat{\theta}}(X, Y, Z)}{1 - w_{\hat{\theta}}(X, Y, Z)} \geq C_1 \frac{w_{\hat{\theta}}(X, Y, Z)}{1 - w_{\hat{\theta}}(X, Y, Z)}$. Получаем:

$$\begin{aligned} \frac{\text{Var}(\hat{\Gamma}(X, Y, Z))}{b[\mathbb{E}(\hat{\Gamma}(X, Y, Z))]^2} &\leq \frac{1}{b} \frac{[1 - \mathbb{E}w_{\hat{\theta}}(X, Y, Z)]^2}{C_1^2 [\mathbb{E}w_{\hat{\theta}}(X, Y, Z)]^2} C_2^2 \text{Var} \left(\frac{w_{\hat{\theta}}(X, Y, Z)}{1 - w_{\hat{\theta}}(X, Y, Z)} \right) \leq \\ &\frac{1}{b} \frac{C_2^2 [1 - \tau]^2}{C_1^2 \tau^2} \frac{[1 - \tau]^2}{\tau^2}, \end{aligned}$$

где первое неравенство верно в силу неравенства Йенсена для $\mathbb{E}(\hat{\Gamma}(X, Y, Z))$, а второе в силу предположения 4. В самом деле, заметим, что в силу неравенства Йенсена для выпуклой функции f , мы имеем: $\mathbb{E}(f(X)) \geq f(\mathbb{E}(X))$. В нашем случае при $f(x) = \frac{x}{1-x}$ имеем:

$$\mathbb{E} \left(\frac{w_{\hat{\theta}}(X, Y, Z)}{1 - \mathbb{E}(w_{\hat{\theta}}(X, Y, Z))} \right) \geq \frac{\mathbb{E}(w_{\hat{\theta}}(X, Y, Z))}{1 - \mathbb{E}(w_{\hat{\theta}}(X, Y, Z))}.$$

Значит, подставляя данное неравенство в $\frac{\text{Var}(\hat{\Gamma}(X, Y, Z))}{b[\mathbb{E}(\hat{\Gamma}(X, Y, Z))]^2}$, получаем обоснование первого перехода. Так как $b(n) \sim \tilde{C}n$, то $I_1 \rightarrow 0$. Здесь следует отметить, что данная оценка справедлива только при $\tau > \tilde{C}n^{-1/4+\epsilon}$ для $\epsilon > 0$. В самом деле, последнее выражение в предыдущей цепочке неравенств стремится к нулю, если: $\frac{1}{n\tau^4} \rightarrow 0$, т.е. $\tau > \tilde{C}n^{-1/4+\epsilon}$.

Рассмотрим I_2 . Заметим, что по условию Липшица:

$$|\log \Gamma(X, Y, Z) - \log \hat{\Gamma}(X, Y, Z)| \leq \frac{1}{\rho} |\Gamma(X, Y, Z) - \hat{\Gamma}(X, Y, Z)|,$$

при $\log \hat{\Gamma}(X, Y, Z) \in [\rho, +\infty)$. Считаем, что $\log \hat{\Gamma}(X, Y, Z)$ отделен от нуля в силу предположения 5. Пользуясь данной оценкой, получаем:

$$I_2 = \left[\mathbb{E}_p \left[\log \Gamma(X, Y, Z) - \log \hat{\Gamma}(X, Y, Z) \right] \right]^2 \leq \frac{1}{\rho^2} \left[\mathbb{E}_p |\Gamma(X, Y, Z) - \hat{\Gamma}(X, Y, Z)| \right]^2 \leq \frac{\eta^2 \beta^2}{\rho^2} = \epsilon \cdot \frac{2\lambda(S)}{\rho^2},$$

где ρ такое, что $\log \hat{\Gamma}(x, y, z) \in [\rho, +\infty)$, а η то же самое, что в лемме 3. Таким образом, оценка f_{LDR}^* является L_2 -состоятельной оценкой величины $I(X; Y|Z)$.

2°. Перейдем к оценке f_{DV}^* , заданной формулой (5). Используя неравенство Коши-Буняковского-Шварца, получаем:

$$\begin{aligned} & \mathbb{E}_p \left[I(X; Y|Z) - \mathbb{E}_p \log \hat{\Gamma}(X, Y, Z) + \mathbb{E}_p \log \hat{\Gamma}(X, Y, Z) + \right. \\ & \quad \left. \log \mathbb{E}_q \hat{\Gamma}(X, Y, Z) - \log \mathbb{E}_q \hat{\Gamma}(X, Y, Z) - f_{DV}^* \right]^2 \leq \\ & 3\mathbb{E}_p \left[I(X; Y|Z) - \left(\mathbb{E}_p \log \hat{\Gamma}(X, Y, Z) - \log \mathbb{E}_q \hat{\Gamma}(X, Y, Z) \right) \right]^2 + \end{aligned}$$

$$3\mathbb{E}_p \left[\frac{1}{b} \sum_{(x,y,z) \in B_{joint}^b} \log \hat{\Gamma}(x, y, z) - \mathbb{E}_p \log \hat{\Gamma}(X, Y, Z) \right]^2 +$$

$$3\mathbb{E}_p \left[\log \frac{1}{b'} \sum_{(x,y,z) \in B_{product}^{b'}} \hat{\Gamma}(x, y, z) - \log \mathbb{E}_q \hat{\Gamma}(X, Y, Z) \right]^2.$$

Перепишем данное выражение в виде суммы $\tilde{I}_1 + \tilde{I}_2 + \tilde{I}_3$. Заметим, что оценка для $\tilde{I}_2$ уже получена. Перейдем к оценкам для $\tilde{I}_1$ и $\tilde{I}_3$. Имеем:

$$\tilde{I}_1 = \mathbb{E}_p \left[I(X; Y|Z) - \left(\mathbb{E}_p \log \hat{\Gamma}(X, Y, Z) - \log \mathbb{E}_q \hat{\Gamma}(X, Y, Z) \right) \right]^2 \leq$$

$$2\mathbb{E}_p \left[\mathbb{E}_p \left[\log \Gamma(X, Y, Z) - \log \hat{\Gamma}(X, Y, Z) \right] \right]^2 +$$

$$2\mathbb{E}_p \left[\log \mathbb{E}_q [\Gamma(X, Y, Z)] - \log \mathbb{E}_q [\hat{\Gamma}(X, Y, Z)] \right]^2.$$

Первое слагаемое было изучено ранее, осталось оценить

$$\mathbb{E}_p \left[\log \mathbb{E}_q [\Gamma(X, Y, Z)] - \log \mathbb{E}_q [\hat{\Gamma}(X, Y, Z)] \right]^2 =$$

$$\left[\log \mathbb{E}_q [\Gamma(X, Y, Z)] - \log \mathbb{E}_q [\hat{\Gamma}(X, Y, Z)] \right]^2 \leq$$

$$\frac{1}{\rho^2} \left[\mathbb{E}_q |\Gamma(X, Y, Z) - \hat{\Gamma}(X, Y, Z)| \right]^2 \leq \frac{\eta^2 \beta^2}{\rho^2} = \epsilon \cdot \frac{2\lambda(S)}{\rho^2},$$

где последнее неравенство верно в силу леммы 2. Рассмотрим теперь третье слагаемое. Применив условие Липшица для $\log \hat{\Gamma}(x, y, z) \in [\rho, +\infty)$, получаем:

$$\mathbb{E}_p \left[\log \frac{1}{b'} \sum_{(x,y,z) \in B_{product}^{b'}} \hat{\Gamma}(x, y, z) - \log \mathbb{E}_q \hat{\Gamma}(X, Y, Z) \right]^2 \leq$$

$$\frac{1}{\rho^2} \mathbb{E}_p \left[\frac{1}{b'} \sum_{(x,y,z) \in B_{product}^{b'}} \hat{\Gamma}(X, Y, Z) - \mathbb{E}_q \hat{\Gamma}(X, Y, Z) \right]^2.$$

Заметим, что в первом пункте уже оценивалась функция такого вида. Проводя аналогичные рассуждения, получаем:

$$\frac{1}{\rho^2} \mathbb{E}_p \left[\frac{1}{b'} \sum_{(x,y,z) \in B_{product}^{b'}} \hat{\Gamma}(X, Y, Z) - \mathbb{E}_q \hat{\Gamma}(X, Y, Z) \right]^2 \leq \frac{1}{b'} \frac{C_2^2 \text{Var}(\hat{\Gamma}(X, Y, Z))}{C_1^2 \rho^2} \leq \frac{1}{b'} \frac{C_2^2 [1 - \tau]^2}{C_1^2 \tau^2}.$$

Откуда видно, что т.к. $b'(n) \sim \bar{C}n$, то $\tilde{I}_3 \rightarrow 0$. Данное неравенство будет верно при $\tau > \tilde{K}n^{-1/2+\epsilon}$ для $\epsilon > 0$. В самом деле, последняя величина в предыдущей цепочке неравенств стремится к нулю, если $\frac{1}{n\tau^2} \rightarrow 0$, что эквивалентно тому, что $\tau > \tilde{K}n^{-1/2+\epsilon}$.

3°. Воспользуемся идеей, примененной в пунктах 1° и 2°. Добавим величину $\mathbb{E}_{NWJ} = 1 + \mathbb{E}_p \log \hat{\Gamma}(X, Y, Z) - \mathbb{E}_q \hat{\Gamma}(X, Y, Z)$ под знаком математического ожидания $\mathbb{E}_p [I(X; Y|Z) - f_{NWJ}^*]^2$. Тогда, оценив математическое ожидание по неравенству Коши-Буняковского-Шварца и неравенству треугольника, получаем слагаемые следующего вида:

$$1. \mathbb{E}_p [I(X; Y|Z) - \mathbb{E}_{NWJ}]^2,$$

$$2. \mathbb{E}_p \left[\frac{1}{b} \sum_{(x,y,z) \in B_{joint}^b} \log \hat{\Gamma}(X, Y, Z) - \mathbb{E}_p \log \hat{\Gamma}(X, Y, Z) \right]^2,$$

$$3. \mathbb{E}_p \left[\frac{1}{b'} \sum_{(x,y,z) \in B_{product}^{b'}} \hat{\Gamma}(X, Y, Z) - \mathbb{E}_q \hat{\Gamma}(X, Y, Z) \right]^2.$$

Для второй и третьей величины были получены соответствующие оценки. Первое математическое ожидание оценивается аналогично: используем неравенство Коши-Буняковского-Шварца и неравенство треугольника, а далее получаем те же слагаемые. $\square$

Перейдем теперь к вопросу асимптотической несмещенности.

Утверждение 1. Пусть выполнены условия (1), (2), (4), предположим также, что $X, Y, Z \in L_2(\Omega)$, тогда $f_{DV}^*, f_{LDR}^*, f_{NWJ}^*$ – асимптотически несмещенные оценки $I(X; Y|Z)$.

Доказательство. 1°. Начнем с f_{LDR}^* . Покажем, что $\mathbb{E}_p f_{LDR}^* \rightarrow I(X; Y|Z)$.
Имеем

$$\mathbb{E}_p f_{LDR}^* = \frac{1}{b} \sum_{(x,y,z) \in B_{joint}^b} \mathbb{E}_p \log \hat{\Gamma}(X, Y, Z) = \mathbb{E}_p \log \hat{\Gamma}(X, Y, Z).$$

Заметим, что в силу теоремы 1, при $h \rightarrow +\infty$ выполняется соотношение

$$\frac{w_{\hat{\theta}}(X, Y, Z)}{1 - w_{\hat{\theta}}(X, Y, Z)} \rightarrow \frac{w_{\min}(X, Y, Z)}{1 - w_{\min}(X, Y, Z)}.$$

Следовательно,

$$\begin{aligned} \log \hat{\Gamma}(X, Y, Z) &= \log \left(\frac{b'(n)}{b(n)} \frac{w_{\hat{\theta}}(X, Y, Z)}{1 - w_{\hat{\theta}}(X, Y, Z)} \right) \rightarrow \\ &\log \left(\frac{b'(n)}{b(n)} \frac{w_{\min}(X, Y, Z)}{1 - w_{\min}(X, Y, Z)} \right) = \\ \log \left(\frac{b'(n)}{b(n)} \frac{w_{\min}(X, Y, Z)}{1 - w_{\min}(X, Y, Z)} \right) &\rightarrow \log \left(\frac{b'(n)}{b(n)} \frac{p_1}{1 - p_1} \frac{1 - p_1}{p_1} \frac{w_{\min}(X, Y, Z)}{1 - w_{\min}(X, Y, Z)} \right) = \\ \log \left(\frac{b'(n)}{b(n)} \frac{p_1}{1 - p_1} \Gamma(X, Y, Z) \right) &= \log \left(\frac{\frac{b'(n)}{b'(n)+b(n)}}{\frac{b(n)}{b'(n)+b(n)}} \frac{p_1}{1 - p_1} \Gamma(X, Y, Z) \right). \end{aligned}$$

Вспомним, что $p_1 = \mathbb{P}(q = 1)$, где $q = \mathbb{I}\{(x, y, z) \in B_{joint}^b\}$. Тогда заметим, что:

$$\frac{b(n)}{b'(n) + b(n)} = \frac{\#(\text{число элементов в } B_{joint}^b \text{ множестве})}{\#(\text{число элементов всего})}.$$

Это частотная оценка для параметра p_1 бернулевской случайной величины.

Поэтому $\frac{b'(n)}{b(n)} \xrightarrow{n \rightarrow +\infty} \frac{1 - p_1}{p_1}$. Получаем:

$$\log \left(\frac{\frac{b'(n)}{b'(n)+b(n)}}{\frac{b(n)}{b'(n)+b(n)}} \frac{p_1}{1 - p_1} \Gamma(X, Y, Z) \right) \rightarrow \log (\Gamma(X, Y, Z)).$$

А значит оценка f_{LDR}^* является асимптотически несмещенной.

2°. Теперь мы хотим доказать, что

$$\mathbb{E}_p \left(\frac{1}{b} \sum_{(x,y,z) \in B_{joint}^b} \log \hat{\Gamma}(x, y, z) - \log \left(\frac{1}{b'} \sum_{(x,y,z) \in B_p^{b'}} \hat{\Gamma}(x, y, z) \right) \right) \rightarrow I(X; Y|Z).$$

В данном случае удобно рассматривать $I(X; Y|Z)$ как вариационную верхнюю оценку из теоремы 2.

$$\mathbb{E}_p \left(\frac{1}{b} \sum_{(x,y,z) \in B_{joint}^b} \log \hat{\Gamma}(x, y, z) - \log \left(\frac{1}{b'} \sum_{(x,y,z) \in B_{product}^{b'}} \hat{\Gamma}(x, y, z) \right) \right) =$$

$$\mathbb{E}_p \log \hat{\Gamma}(x, y, z) - \log \mathbb{E}_q \left(e^{\log \hat{\Gamma}(x,y,z)} \right).$$

Получили правую часть формулы (5). При этом, в силу того, что по теореме 1 при $h \rightarrow \infty$ выполняется $\hat{\Gamma}(x, y, z) \rightarrow \Gamma(x, y, z)$, видим, что верна асимптотическая несмещенность оценки f_{DV}^* .

3°. Вывод асимптотической несмещенности f_{NWJ}^* повторяет предыдущий пункт. Единственным отличием является то, что вместо правой части формулы (5), следует рассмотреть оценку величины $\mathbb{E}_p f(X, Y, Z) - e^{-1} \mathbb{E}_q e^{f(X,Y,Z)}$. $\square$

4 Компьютерные эксперименты

Рассмотрим результаты компьютерного моделирования в случае выборки из гауссовского распределения и в случае выборки из распределения с "тяжелыми" хвостами.

1. Рассмотрим $X \sim N(0, \sigma_x^2 I_d)$, $Y|X \sim N(X, \sigma_y^2 I_d)$, $Z|Y \sim N(Y, \sigma_z^2 I_d)$. Тогда:

$$I(X; Y|Z) = \frac{d}{2} \log \left(1 + \frac{\sigma_x^2}{\sigma_y^2} \right) - \frac{d}{2} \log \left(1 + \frac{\sigma_x^2}{\sigma_y^2 + \sigma_z^2} \right). \quad (17)$$

Доказательство данной формулы можно найти в [18].

2. Возьмем $X \sim Cauchy(0, 1)$, $Y|X \sim Cauchy(X, 1)$, $Z|Y \sim Cauchy(Y, 2)$.

Утверждение 2. Для случайных величин Y, Z верно следующее:

$$Y \sim Cauchy(0, 2),$$

$$Z \sim Cauchy(0, 4).$$

Доказательство. По формуле полной вероятности: $p(z) = \int_{\mathbb{R}} p(z|y)p(y)dy$.

Таким образом, для доказательства $Y \sim Cauchy(0, 2)$, надо рассмотреть следующий интеграл:

$$\frac{1}{\pi^2} \int_{-\infty}^{+\infty} \frac{1}{1+x^2} \frac{1}{1+(y-x)^2} dx =$$

$$\begin{aligned} & \frac{1}{\pi^2} \int_{-\infty}^{+\infty} \left[\frac{2x+y}{(y^3+4y)(1+x^2)} - \frac{2x-3y}{(y^3+4y)(1+(y-x)^2)} \right] dx = \\ & \frac{1}{\pi^2} \left[\int_{-\infty}^{+\infty} \frac{2x}{(y^3+4y)(1+x^2)} dx + \int_{-\infty}^{+\infty} \frac{1}{(y^2+4y)(1+x^2)} dx - \right. \\ & \left. \int_{-\infty}^{+\infty} \frac{2x-2y}{(y^3+4y)(1+(y-x)^2)} dx + \int_{-\infty}^{+\infty} \frac{1}{(y^2+4)(1+(y-x)^2)} dx \right] = \frac{1}{\pi} \frac{2}{4+y^2}. \end{aligned}$$

Доказательство $Z \sim Cauchy(0, 4)$ аналогично. $\square$

Для того чтобы найти $I(X; Y|Z) = I(X; Y, Z) - I(X; Z) = I(X; Y) - I(X; Z)$, требуется вычислить два интеграла:

$$\begin{aligned} I_1 &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} p(y|x)p(x) \log \frac{p(y|x)}{p(y)} dx dy = \\ & \frac{1}{\pi^2} \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \frac{1}{1+(y-x)^2} \frac{1}{1+x^2} \log \frac{4+y^2}{2(1+(y-x)^2)} dx dy. \\ I_2 &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} p(z|x)p(x) \log \frac{p(z|x)}{p(z)} dx dz = \\ & \frac{1}{\pi^2} \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \frac{2}{4+(z-2x)^2} \frac{1}{1+x^2} \log \frac{2(16+z^2)}{4(4+(z-2x)^2)} dx dz. \end{aligned}$$

К сожалению, интегралы такого вида сложно вычислить аналитически. Методами численного интегрирования получено: $I_1 - I_2 \approx 0.37$.

Предлагается рассмотреть следующие величины:

- Среднеквадратичную ошибку между результатом работы алгоритма и изучаемой величиной.

$$RMSE(y, \{\hat{y}\}_{i=1}^m) = \frac{1}{m} \sum_{i=1}^m (y - \hat{y}_i)^2, \quad (18)$$

где y - истинное значение изучаемой величины, а $\{\hat{y}\}_{i=1}^m$ - значения, полученные алгоритмом.

- Среднюю абсолютную ошибку между результатом работы алгоритма и изучаемой величиной.

$$MAE(y, \{\hat{y}\}_{i=1}^m) = \frac{1}{m} \sum_{i=1}^m |y - \hat{y}_i|, \quad (19)$$

где y - истинное значение изучаемой величины, а $\{\hat{y}\}_{i=1}^m$ - значения, полученные алгоритмом.

Было проведено компьютерное моделирование, при размере выборки $N \in \{1000, 5000, 10000, 50000, 100000\}$. В каждом случае было выполнено $T_{\max} = 1000$ прогонок алгоритма. График, приведенный ниже, показывает зависимость ошибки от размера выборки для разных оценок в случае выборок из гауссовского распределения.




Рис. 1: Гауссовский случай.

Как видно из результатов компьютерного моделирования, с увеличением размера выборки ошибки уменьшаются. Таким образом, данные графики хорошо иллюстрируют результат теоремы 3 и утверждения 1.

Для случая выборки из распределения Коши ситуация иная. Как показывает Рис.2 в случае распределения Коши, величины ошибок не уменьшаются. Таким образом, при размерах выборки $N \leq 10^5$ данные оценки не рекомендуются применять.




Рис. 2: Случай распределения Коши.

На основании эксперимента можно сделать предположение, что данные нейросетевые оценки можно применять на практике, если известно, что распределение имеет конечный второй момент. При этом, как видно из Рис.1, для рассмотренного примера гауссовских распределений лучшей является оценка f_{DV}^* .

5 Сопоставление с предшествующими результатами

В этой части предлагается сравнить результаты, полученные в данной работе с теми, которые обсуждались ранее.

В статье [23] авторы изучали способы задания непараметрических оценок условной взаимной информации Реньи. Для этого они также строили подвыборки индексов из множества $\{1, \dots, n\}$: J_1, J_2, J_3, J_4 , для которых $|J_1| + |J_2| + |J_3| + |J_4| = n$, где $|J|$ обозначает мощность множества J . Базируясь на них, они получили громоздкую оценку вида:

$$\begin{aligned} \hat{Q}_3 = & \frac{1}{N} \sum_{n=1}^N \frac{(c_{xyz}|J_1 \setminus \{n\}|)^{1-\alpha} \rho_{xyz, J_1 \setminus \{n\}}^{d_{xyz}(1-\alpha)}(X_n; Y_n; Z_n)}{(c_{xz}|J_2 \setminus \{n\}|)^{1-\alpha} \rho_{xz, J_2 \setminus \{n\}}^{d_{xz}(1-\alpha)}(X_n; Z_n)} \\ & \times \frac{(c_z|J_4 \setminus \{n\}|)^{1-\alpha} \rho_{z, J_4 \setminus \{n\}}^{d_z(1-\alpha)}(Z_n)}{(c_{yz}|J_3 \setminus \{n\}|)^{1-\alpha} \rho_{yz, J_3 \setminus \{n\}}^{d_{yz}(1-\alpha)}} B^2. \end{aligned} \quad (20)$$

Здесь N - размер выборки, $c_{xyz}, c_{xz}, c_{yz}, c_z$ обозначают объем единичного шара в размерностях $\{d_x + d_y + d_z, d_x + d_z, d_y + d_z, d_z\}$ соответствен-

но, J_1, J_2, J_3, J_4 – непересекающиеся подвыборки индексов. Для каждого $1 \leq n \leq N$ $\rho_{xyz, J_1 \setminus \{n\}}^{d_{xyz}(1-\alpha)}(X_n; Y_n; Z_n)$ – это расстояние от (X_n, Y_n, Z_n) до $\{(X_i, Y_i, Z_i)\}_{i \in J_1}$. Остальные расстояния определяются аналогично. В своей статье авторы указывают, что для данной оценки верна L_2 – состоятельность при $\alpha < 1$. Их доказательство опирается на утверждения из [15] и свойства известного распределения Эрланга (гамма-распределения с целыми параметрами). Оценка для исследуемой нами величины, получается предельным переходом $\hat{Q}_3$ при $\alpha \rightarrow 1$. Авторы утверждают, что условия теоремы выполняются и для условной взаимной информации.

В упомянутой статье [15] авторы, основываясь на методе k -ближайших соседей, приводят непараметрические оценки для энтропии Реньи и взаимной информации. Они изучают различные стороны вопроса: скорость сходимости, связь изучаемой величины с уравнением Фоккера-Планка, влияние k на оценки и т.д. Авторы доказывают ряд теорем, которые показывают L_2 – состоятельность и несмещенность полученных оценок. Основной идеей их доказательств является применение следующей теоремы Лебега о дифференцируемости, см., например, [2].

Теорема 4. Пусть $g(x) \in L_1(\mathbb{R}^m)$, тогда для любой последовательности открытых шаров $\mathcal{B}(x, R_k)$, с $R_k \rightarrow 0$, при $k \rightarrow \infty$ и для почти всех по мере Лебега $x \in \mathbb{R}^m$,

$$\lim_{k \rightarrow \infty} \frac{1}{V_m R_k^m} \int_{\mathcal{B}(x, R_k)} g(t) dt = g(x), \quad (21)$$

где V_m – объем единичного шара размерности m .

Сравнивая непараметрический подход, представленный в [15] и [23], с параметрическим подходом статьи [17], отметим следующее.

1. Доказательства, представленные в статьях [15], [23] опираются на меньшее количество допущений. Так, например, авторы не вводят ограничения на величину k (предположение 1).
2. С практической точки зрения, реализация оценок, представленных в [17], удобнее. Проблема выражения (20) в том, что при большой размерности пространства $\mathbb{R}^D$ и большом N , будет накапливаться вычислительная ошибка компьютера. Заметим, что если (20) имеет компактную запись, то данное затруднение удастся преодолеть.

6 Выводы

В предположении (1)–(5) в теореме 3 дипломной работы была показана L_2 -состоятельность оценок, предложенных авторами в статьях [17], [18]. Для этого использовались: условие Липшица функции $\log x$ при $x \in [\rho, +\infty)$, где $\rho > 0$, лемма 2 (известная как дельта-метод), а также неравенство Йенсена. В ходе доказательства было показано, что некоторые из условий (1) – (5) можно ослабить. Так, например, можно отдельно рассмотреть случаи, когда $I(X; Y|Z) = 0$ или ослабить (4), рассмотрев при каких $\tau(n)$ выполнена теорема 3.

В предположении (1), (2), (4) была показана асимптотическая несмещенность оценок, приведенных в [17], [18]. Здесь ключевым моментом является использование теоремы 2.2 из [11], которая позволяет приближать борелевские функции с помощью семейства Σ_3 .

Также, в дипломной работе было проведено компьютерное моделирование на языке Python. Численные расчеты показали, что в случае выборки из гауссовского распределения, среднеквадратическая и средняя абсолютная ошибки оценок изучаемых величин малы. В случае выборки из распределения Коши, было продемонстрировано, что среднеквадратическая и средняя абсолютная ошибки практически не меняются для рассмотренных больших размеров выборки.

Стоит отметить, что доказательства теоремы 3 и утверждения 1 опирались на ряд предположений. На практике эти допущения часто выполняются, как утверждается в [17]. При этом доказательство теоремы 3 заслуживает внимания, поскольку не опирается на свойства распределения Эрланга, в отличие от доказательств теорем из [23]. Отметим также, что утверждение 1 выполняется при меньшем числе допущений. Так, например, мы не требуем $I(X; Y|Z) \in [Q, +\infty)$, где $Q > 0$.

Литература

- [1] А.И.Галушкин, *Синтез многослойных систем распознавания образов*, М.: Энергия, 1974.
- [2] J.Benedetto, W.Czaja, *Integration And Modern Analysis*, Springer, (2009), 361–364.
- [3] A.Bulinski, A.Kozhevin, *Statistical Estimation of Mutual Information for Mixed Model*, Methodology and Computing in Applied Probability, **23**:1 (2021), 123-142.
- [4] T.Cover, *Elements of Information Theory*, New York: Wiley-Interscience, 2006.
- [5] M.Donsker, S.Varadhan, *Asymptotic evaluation of certain Markov process expectations for large time*, Communinty Pure Applied Mathematics, **28**:1 (1975), 1–47.
- [6] J.Doob, *The Limiting Distributions of Certain Statistics*, The Annals of Mathematical Statistics, **6**:3 (1935), 160-169.
- [7] F.Fleuret, *Fast Binary Feature Selection with Conditional Mutual Information*, Journal of Machine Learning Research, 5 (2004), 1531–1555.
- [8] T.Hill, L.Marquez, M.O’Connor, W.Remusa, *Artificial neural network models for forecasting and decision making*, International Journal of Forecasting, **10**:1 (1994), 5-15.
- [9] R.Gray, *Entropy and Information Theory*, Springer-Verlag, 1990.
- [10] G.Hinton, D. Rumelhart, R.Williams, *Learning Internal Representations by Error Propagation*, Parallel Distributed Processing, **1** (1986), 318–362.
- [11] K.Hornik, M.Stinchcombe, H.White, *Multilayer feedforward networks are universal approximators*, Neural Networks, **2**:5 (1989), 359–366.
- [12] J.Huang, J.Chai, S.Cho, *Deep learning in finance and banking: A literature review and classification*, Frontiers of Business Research in China, **14**:13 (2020).
- [13] M. Johnson, D. Duvenaud, A. Wiltchko, S. Datta, R. Adams, *Composing graphical models with neural networks for structured representations and fast inference*, arXiv:1603.06277.

- [14] A.Kozhevin, *Feature selection based on statistical estimation of mutual information*, Siberian Mathematical Journal, **18**:1 2021, 720-728.
- [15] N.Leonenko, L. Pronzato, V. Savani, *A class of Rényi information estimators for multidimensional densities*, Annals of Statistics, **36**:5 (2008), 2153–2182.
- [16] W.McGill, *Multivariate information transmission*, 1954.
- [17] S.Molavipur, G.Bassi, M.Skoglund, *Neural Estimators for Conditional MutualInformation Using Nearest Neighbors Sampling*, IEEE transactions on signal processing, **69** (2021), 766-780.
- [18] S.Mukherjee, H.Asnani, S.Kannan, *Classifier based Conditional Mutual Information Estimation*, arXiv:1906.01824v1, 2019.
- [19] X.Nguyen, M.J.Wainwright, M.I.Jordan, *Estimating divergence functionals and the likelihood ratio by convex risk minimization*, IEEE Trans. Inf. Theory, **56**:11 (2010), 5847–5861.
- [20] F.Rosenblatt, *The perceptron: A probabilistic model for information storage and organization in the brain*, Psychological Review, **65**:6 (1958), 386–408.
- [21] S.Ruder, *An overview of gradient descent optimization algorithms*, arXiv:1609.04747v2, 2016.
- [22] M.Stone, *The Generalized Weierstrass Approximation Theorem*, Mathematics Magazine, **21**:4 (1948), 167–184.
- [23] J.Schneider, B. Póczos, *Nonparametric Estimation of Conditional Information and Divergences*, Carnegie Mellon University, 2012.
- [24] Z.Tan, S.Wang, Z.Yang, G.Chen, X.Huang, M.Sun, Y.Liu, *Neural machine translation: A review of methods, resources, and tools*, AI Open, **1**:1 (2020), 5-21.